AZURE DAY TORINO 2026

AI Gateway: The Missing Layer of Enterprise AI



Luca Congiu

Microsoft

TECHNOLOGY

TORINO.NET

NET CODE

AZURE DAY

Platinum Sponsor

Microsoft

msc TECHNOLOGY

Technical Sponsor

TORINO NET

NET CODE

JET BRAINS



INTRODUZIONE

Perché serve un AI Gateway

01

Chiavi dei provider sparse

Chiavi ed endpoint dei provider replicati nel codice di ogni app

02

Token e TPM condivisi

Più app consumano la stessa quota TPM: una sola può saturarla

03

Costi

Consumo di token difficile da attribuire e da limitare per team

04

Sicurezza e content safety

Prompt e risposte vanno filtrati in modo coerente per tutti

05

Osservabilità

Servono log, metriche e trace su prompt, token e costi

06

Agenti e tool MCP

Gli agenti chiamano modelli e tool: anche i tool vanno governati

Serve un punto unico di controllo tra app e agenti da una parte, modelli e tool dall'altra.



INTRODUZIONE

Due modi di fare AI Gateway in APIM

Soluzione 1

Capacità AI gateway in tutti i tier APIM

Un set di capacità che estende il gateway API esistente

- ✓ Tier classic e v2, da Consumption a Premium v2
- ✓ Policy XML con espressioni
- ✓ Disponibilità delle capacità variabile per tier

Soluzione 2

PUBLIC PREVIEW

Nuovo tier dedicato AI Gateway

Gateway fully managed per carichi AI

- ✓ Un unico posto per modelli e tool MCP
- ✓ Portale dedicato, policy a card senza XML
- ✓ Provisioning in circa un minuto



CLASSIC APIM



Capacità, non un prodotto separato

Un set di capacità che estende il gateway API esistente: non un'offerta separata.

DISPONIBILE IN TUTTI I TIER

Classic	Consumption	Developer	Basic	Standard	Premium
v2	Basic v2	Standard v2	Premium v2		

Da verificare in fase di design
La disponibilità delle singole capacità AI gateway varia per tier



Modelli, MCP e agenti dietro un gateway

API di modelli

OpenAI · Chat Completions e Responses

Anthropic · Messages API
Oggi disponibile solo nei tier v2

Google Vertex AI

Modelli in Microsoft Foundry o di provider terzi
Ad esempio Amazon Bedrock

Unified model API PREVIEW
Un solo endpoint OpenAI-compatibile, con traduzione del formato

MCP e agenti

REST API → MCP server
Esporre API esistenti come tool MCP

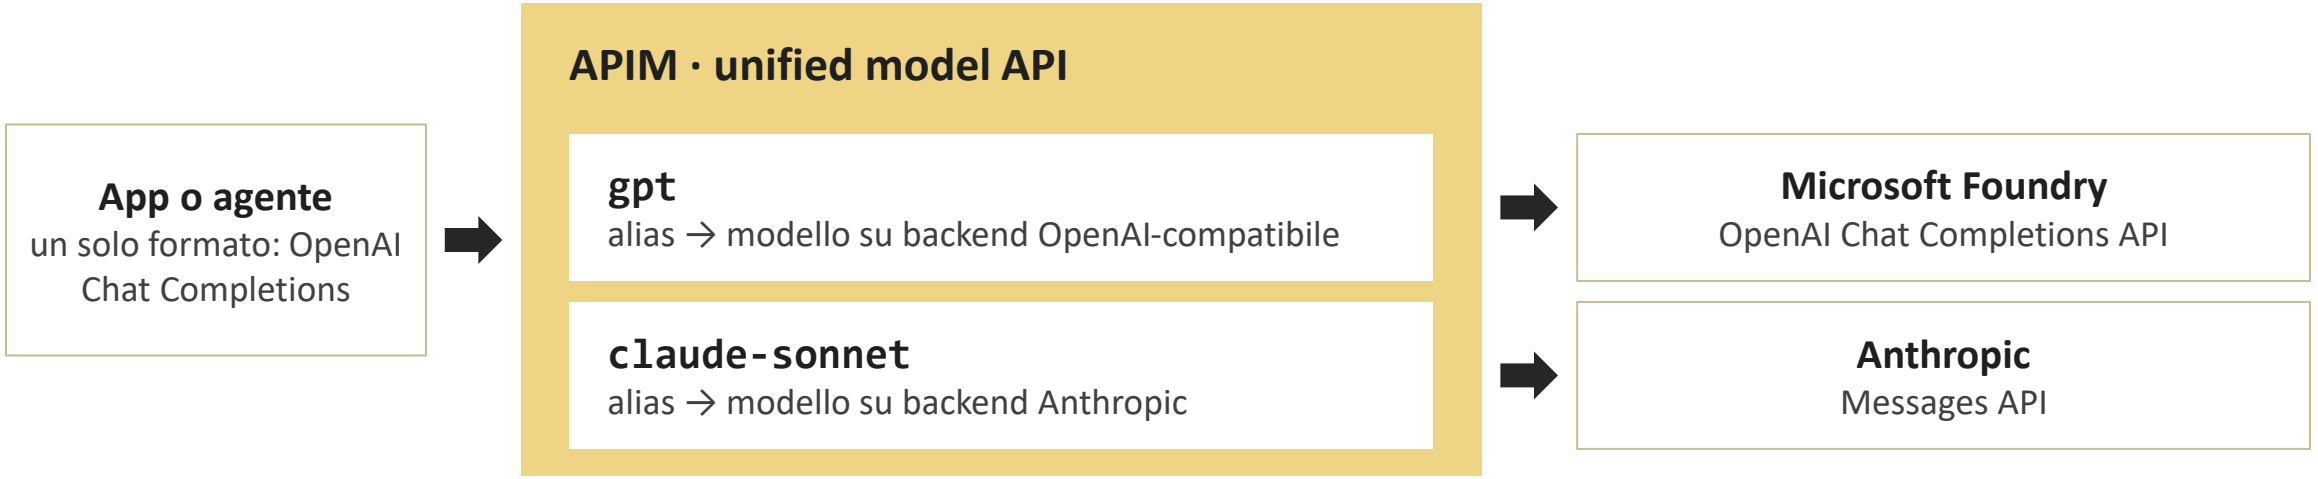
MCP passthrough
Verso MCP server già esistenti

Agenti A2A
Import di agent API A2A

Wizard di import
Con managed identity

Unified model API e model alias

PREVIEW



Traduzione automatica del formato · Tier: Developer, Basic, Standard, Premium e tier v2 · classic: AI Gateway Early release channel

Un solo formato

Il client usa OpenAI Chat Completions, qualunque sia il formato del backend

Policy unificate

Osservabilità, sicurezza e governance uguali per tutti i provider

Alias e failover

Failover tra provider; upgrade o A/B test cambiando solo il target dell'alias

Auth verso il backend

Header (api-key / Authorization) o managed identity di sistema o utente

Token governance con llm-token-limit

LIMITE

Token al minuto (TPM) oppure quota oraria, giornaliera, settimanale, mensile o annuale

COUNTER KEY

Qualsiasi chiave: subscription key, indirizzo IP o un'espressione di policy

STIMA

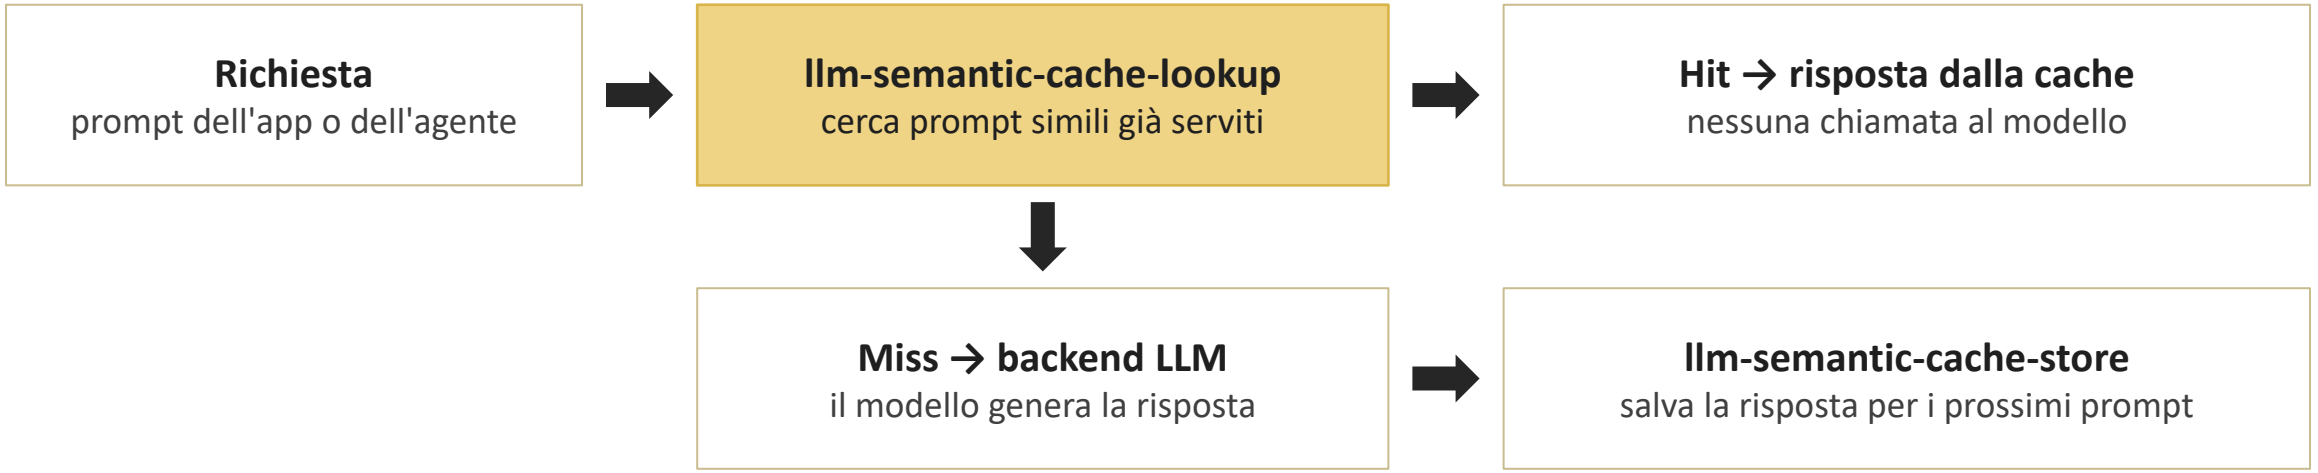
Precalcolo dei prompt token prima di inoltrare la richiesta al backend

Esempio di policy · inbound

```
<llm-token-limit
  counter-key="@(context.Subscription.Id)"
  tokens-per-minute="500"
  estimate-prompt-tokens="false"
  remaining-tokens-variable-name="remainingTokens">
</llm-token-limit>
```

500 token al minuto per subscription; i token residui finiscono nella variabile remainingTokens.

Semantic caching e scalabilità



Cosa serve

Azure Managed Redis o una cache compatibile RediSearch, più un deployment Embeddings API.

Scalare il gateway

Scale unit e gateway regionali multi-region: le opzioni dipendono dal tier.



Resilienza: load balancing e circuit breaker

BACKEND POOL · 4 MODALITÀ

Round-robin	distribuzione uniforme
Weighted	pesi per backend
Priority-based	prima i backend prioritari
Session-aware	affinità di sessione

ESEMPIO: PRIORITÀ SU PTU, SPILL SU PAYG

Backend pool
priority-based

→ **PTU · priorità 1**
capacità riservata

→ **PAYG · priorità 2**
spill quando PTU è saturo

Circuit breaker

Esclude temporaneamente il backend in errore; la trip duration può essere dinamica, letta dall'header Retry-After.



Sicurezza e osservabilità end-to-end

App e agenti
chiamano modelli e tool

APIM · AI gateway
- Managed identity verso i servizi AI
- OAuth via credential manager verso API e MCP
- Content safety con Azure AI Content Safety

Servizi AI e MCP
modelli, API e tool

telemetria

Azure Monitor

Log di prompt e completion

Application Insights

Metriche per consumer; llm-emit-token-metric con dimensioni custom

Dashboard integrata

Vista d'insieme sull'uso dei modelli

Content safety con llm-content-safety

Richiesta o risposta
prompt, completion, MCP, A2A

→

llm-content-safety
policy APIM

→

Backend
solo se il contenuto è ok

↓

Azure AI Content Safety
via backend APIM e managed identity

403

Contenuto dannoso: APIM blocca

Categorie di danno, blocklist custom, shield contro gli attack pattern

PREREQUISITI

- ✓ Risorsa Azure AI Content Safety, raggiunta da un backend APIM
- ✓ Managed identity di APIM con ruolo Cognitive Services User

ATTRIBUTI CHIAVE

- ✓ window-size: solo risposte, default 1.000 caratteri; prompt sempre 10.000
- ✓ output-type: FourSeverityLevels (0, 2, 4, 6) o EightSeverityLevels (0–7)

ATTENZIONE IN STREAMING

La policy smette di inoltrare senza un codice d'errore esplicito: l'agente deve gestire lo stop improvviso (timeout e percorso d'errore).

Token metrics e FinOps

llm-emit-token-metric · dimensioni custom per IP, API e utente

```
<llm-emit-token-metric namespace="llm-metrics">
  <dimension name="Client IP" value="@(context.Request.IpAddress)" />
  <dimension name="API ID" value="@(context.Api.Id)" />
  <dimension name="User ID"
    value="@(context.Request.Headers.GetValueOrDefault("x-user-id", "N/A"))" />
</llm-emit-token-metric>
```

Log delle LLM API

Token usage, prompt e completion per billing e audit; analisi in Application Insights e dashboard integrata

Novità Build 2026

Log di reasoning, cached e audio token in Application Insights: OpenAI Chat Completions, OpenAI Responses, Anthropic Messages

Perché conta

Chargeback per team, API e utente, anche con i modelli di reasoning



AI gateway dentro Microsoft Foundry

Da Microsoft Foundry

PREVIEW

1. Quote e rate limit per i deployment di modelli
2. Registrazione di agenti ovunque, nel control plane di Foundry
3. Registrazione di tool MCP

Nell'esperienza APIM completa

Scenari avanzati:

- ✓ Custom policy
- ✓ Enterprise networking
- ✓ Gateway federati

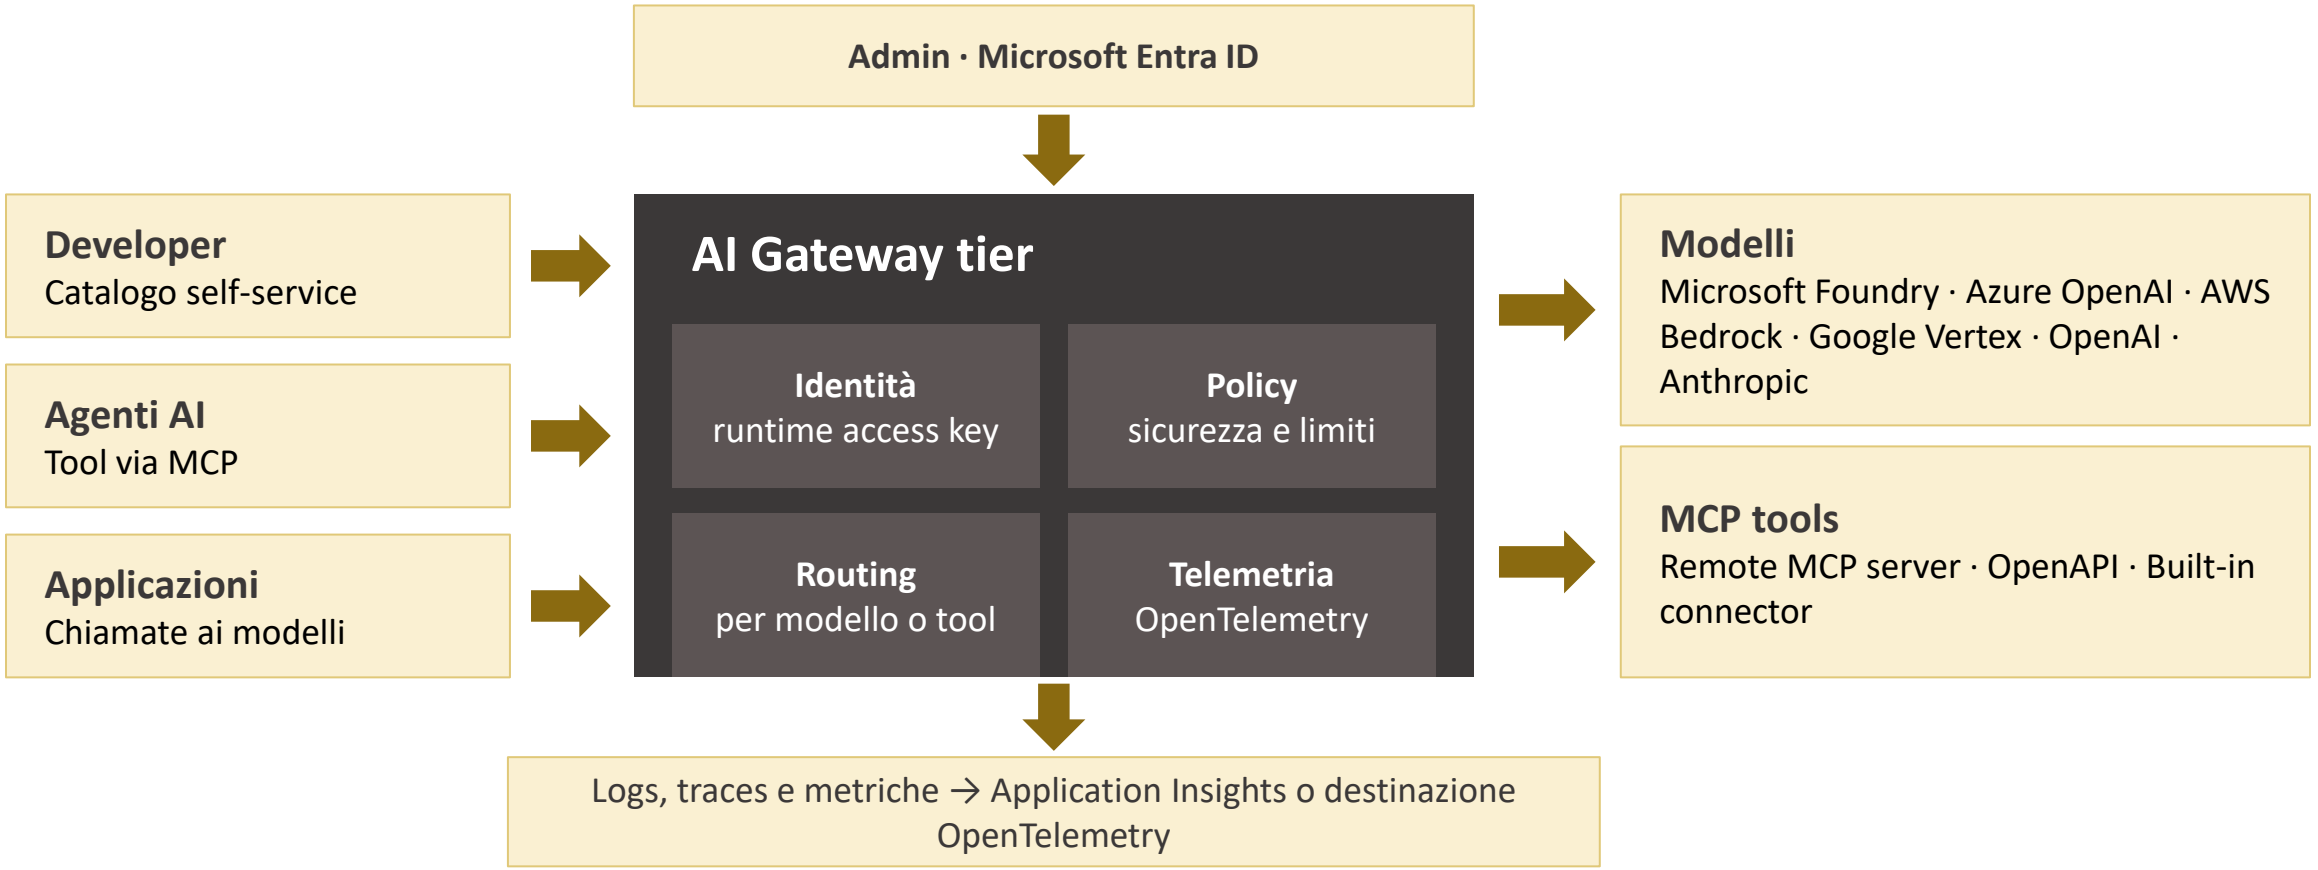
Early release channel delle funzionalità AI gateway disponibile nei tier classic.



NEW AI GATEWAY TIER

ARCHITETTURA

Architettura end-to-end





COME FUNZIONA

Una richiesta, quattro passi

```
POST …/default/models/openai/v1/chat/completions  ·  header api-key
```

1

Autentica

Verifica la runtime access key nell'header api-key.

2

Applica policy

Valuta le policy del modello o del tool di destinazione.

3

Instrada

Campo model per i modelli, nome del tool per i tool, con le credenziali del backend.

4

Risponde

Restituisce la risposta ed emette telemetria OpenTelemetry: token e latenza.

CICLO DI VITA

Connect → Publish → Govern → Observe → Scale



MODELLI

Tutti i modelli, un endpoint

```
Route    https://<gateway>.azure-api.net/default/models/*
```

OPENAI-COMPATIBLE

/models/openai/v1

Microsoft Foundry · Azure OpenAI · AWS Bedrock · Google Vertex · OpenAI

Routing exact-match sul campo model: nomi univoci

ANTHROPIC

/models/anthropic/v1/messages

Custom provider con Messages API passthrough

Formato nativo Anthropic Messages

Import from Foundry

Il wizard rileva i deployment delle risorse Foundry e Azure OpenAI.

Add custom model

Bedrock, Vertex, OpenAI, Anthropic o qualsiasi endpoint OpenAI-compatible.

API supportate

OpenAI Chat Completions, OpenAI Responses, Anthropic Messages.

Onboarding dei modelli – nel dettaglio

Prefisso /default/models: il segmento successivo è il formato API del provider.

```
https://<gateway>.azure-api.net/default/models/openai/v1/chat/completions
https://<gateway>.azure-api.net/default/models/openai/v1/responses
https://<gateway>.azure-api.net/default/models/anthropic/v1/messages
```

Import from Foundry

Foundry · Azure OpenAI · Azure AI Services

- Il wizard rileva i deployment; la selezione è per account Foundry e importa tutti i suoi deployment
- Auth: managed identity (consigliata) o key-based
- Con la managed identity il wizard può abilitare l'identità system-assigned e assegnare il ruolo Foundry User
- Import batch tra più subscription (release agosto 2026)

VERIFYING REQUIREMENTS · PER ACCOUNT

1 · Autenticazione configurata correttamente

↓

2 · Nessun conflitto di nomi dei modelli

↓

OK
account importato

KO
saltato con warning, gli altri proseguono

Nomi dei modelli univoci tra tutti i provider: routing exact-match su model



Onboarding dei modelli – custom e Anthropic

Add custom model

Bedrock · Vertex · OpenAI · Anthropic · altri

- Base URL dell'endpoint, nome dell'header di auth (es. Authorization) e API key
- Per modello scegli gli endpoint: OpenAI chat completions, OpenAI responses, Anthropic messages, Other
- Nessuno step di validazione separato

Anthropic passthrough

Messages API in formato nativo

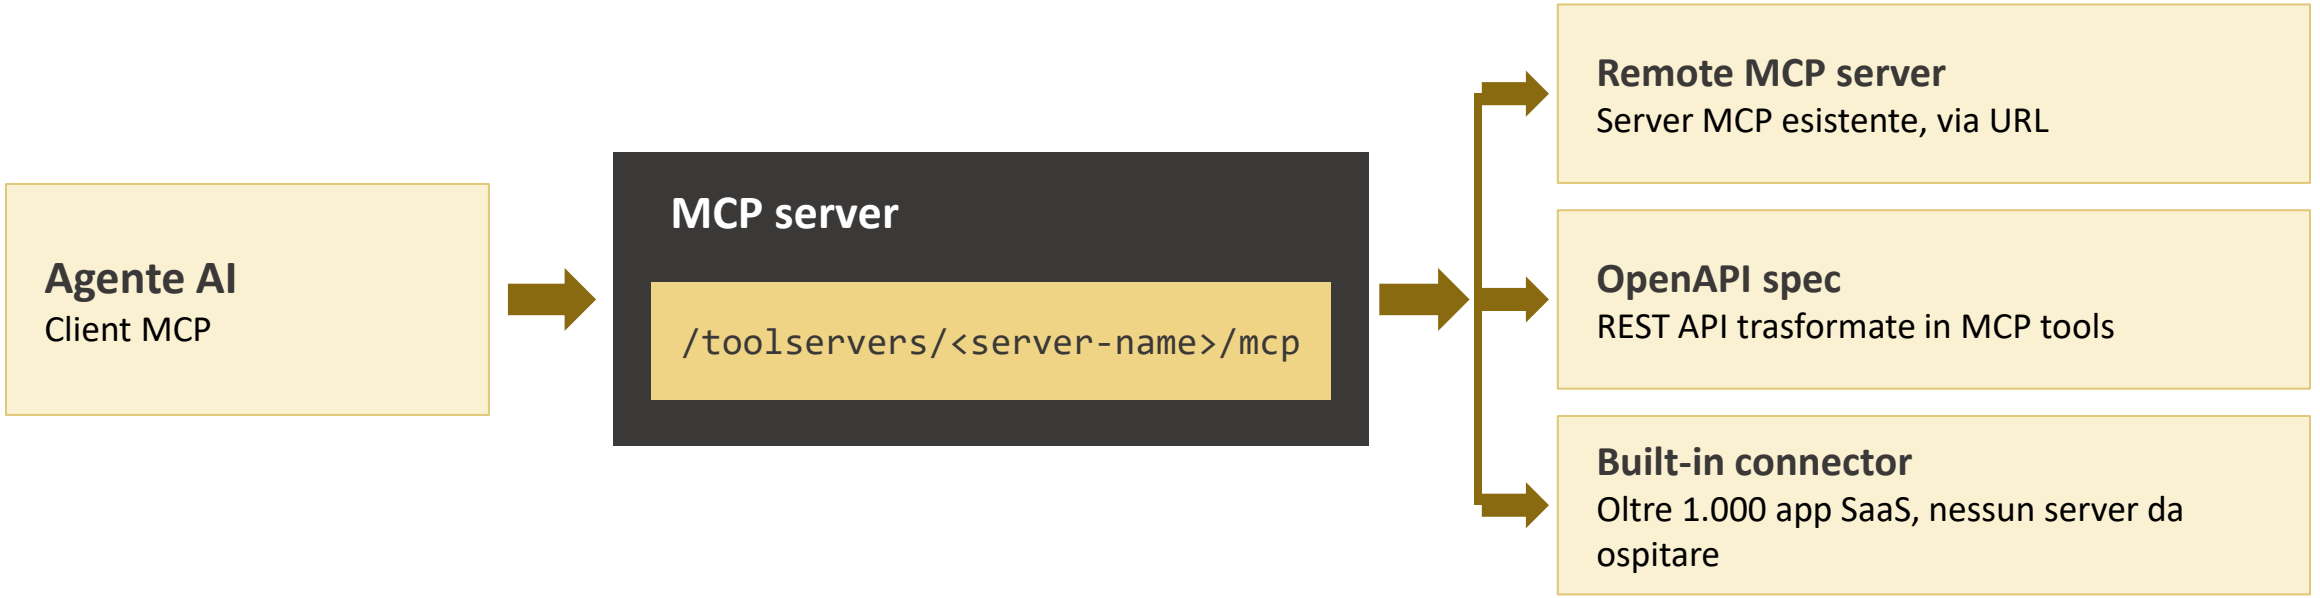
- Base URL: https://api.anthropic.com
- Header di auth: x-api-key
- Il gateway conserva e inietta la chiave del provider
- Inoltra l'header anthropic-version del chiamante

```
# Anthropic Python SDK tramite il gateway
client = anthropic.Anthropic(
    base_url="https://<gateway>.azure-api.net/default/models/anthropic",
    api_key="unused",
    default_headers={"api-key": "<runtime-access-key>"},
)
```

api_key="unused" serve solo all'SDK: la chiave runtime viaggia nell'header api-key.

Tool MCP federati, un endpoint

Ogni operazione diventa un tool: l'agente si connette una volta e li scopre tutti.



Auth verso i backend	None	API Key	OAuth 2.0	Managed identity



MCP server – nel dettaglio

1 · Crea l'MCP server → 2 · Collega i backend → 3 · Esponi i tool

Backend type	Quando usarlo	Input	Risultato
MCP server	Hai già un endpoint MCP remoto	URL dell'endpoint MCP (SSE o streamable HTTP)	Tool del server remoto, federati
OpenAPI spec	Hai una REST API da esporre come tool	Documento OpenAPI (upload, URL o incolla)	Tool MCP generati dalle operazioni selezionate; summary/description → descrizione del tool
Built-in connector	App SaaS comune, senza ospitare un server	Connettore + connessione (es. Microsoft 365, Teams, GitHub, Salesforce etc); con OAuth viene chiesto il consenso	Azioni del connettore come tool MCP

MCP server – endpoint, auth e namespacing

```
Endpoint  https://<gateway>.azure-api.net/default/toolservers/<server-name>/mcp
Header    api-key: <runtime-access-key>
Body      {"jsonrpc":"2.0","id":1,"method":"tools/list"}
```

Namespacing dei tool

Ogni tool è prefissato con il nome del backend: tool con lo stesso nome (es. create_issue) su backend diversi non collidono.

Backend A
create_issue

Backend B
create_issue

Due tool distinti, prefissati dal backend

Auth verso i backend

- None
- API Key
- OAuth 2.0
- Managed identity

API Key: valori cifrati at rest

PREVIEW · LIMITAZIONE
Stato OAuth 2.0 auto-dichiarato: verifica che i tool compaiano.



IDENTITÀ E CHIAVI

Chi accede, e con quale chiave

Admin
Microsoft Entra ID

App e agenti
runtime access key

`api-key`

AI Gateway tier

managed identity
o provider key

Backend
modelli e MCP tools

Runtime access key

Si crea nella pagina Keys del portale

Viaggia nell'header api-key di ogni richiesta

È gateway-scoped: raggiunge ogni modello e tool

BEST PRACTICE

Una chiave per applicazione e ambiente, con least privilege.



Sicurezza: chiavi runtime

Ogni applicazione o agente si autentica al gateway con una chiave runtime.

1 · Crea

Keys > Create API key, con nome stabile e owner

2 · Conserva

In un secret manager: mai in codice, build log, notebook o chat

3 · Ruota

Regolarmente e quando cambia l'owner

4 · Revoca

Se esposta: ruota o revoca la chiave e analizza i log

PREVIEW · SCOPE DELLE CHIAVI

Ogni chiave è gateway-scoped

Accesso a tutti i modelli e tool pubblicati; lo scoping per singolo asset non è ancora disponibile.

BEST PRACTICE

Una chiave per applicazione e ambiente

Nome stabile e owner per ogni chiave; il gateway può ruotarla o revocarla.



Sicurezza: managed identity verso i backend

System-assigned

Legata al ciclo di vita del gateway; semplice con un solo gateway

User-assigned

Condivisa tra più gateway, oppure identità separate per ciascun backend

Ruolo Foundry User sulla singola risorsa Foundry o Azure OpenAI

Scope più ristretto possibile; il wizard di import può assegnarlo.

TROUBLESHOOTING

Errore	Verifica	Poi
401	L'import usa la managed identity?	Il backend accetta Entra ID?
403	Ruolo Foundry User a livello di risorsa?	Attendi la propagazione del ruolo

Usa una API key solo se il provider non supporta la managed identity.

Fonte: Microsoft Learn – Govern, secure, and operate AI Gateway tier



GOVERNANCE

Policy come card, non XML

Si applicano a livello globale o al singolo modello o tool, configurate nel portale.

Content safety

Azure AI Content Safety su prompt e input dei tool

Soglie per categoria: hate, sexual, violence, self-harm, su 4 o 8 livelli di severità

Prompt Shields contro jailbreak e prompt injection

Blocklist personalizzate

Azione: block, log o entrambe

Richiede una risorsa Azure AI Content Safety

BEST PRACTICE

Log-only → **Tuning** → **Block**

IP filter

Allow/deny di CIDR IPv4 e IPv6; con le runtime key per una defense in depth.

Token rate limit

Limita il throughput di token, prompt più completion.

Request rate limit

Limita il volume di richieste in una finestra mobile di un minuto.



Policy: come vengono valutate

Portale: card visuali · Control plane: oggetti JSON strutturati, auditabili e applicabili a una flotta di gateway con Azure Policy · niente XML, fragment o espressioni.

Richiesta verso un modello o un MCP tool

Valutazione di tutte le policy applicabili, prima dell'inoltro

TUTTE SUPERATE
Inoltro al backend

UNA POLICY BLOCCA
Errore al chiamante; il backend non viene chiamato

Policy	Se blocca	Si applica a
Content safety	400	Modelli e MCP tool
IP filter	403	Modelli e MCP tool
Token rate limit	429 + Retry-After	Modelli
Request rate limit	429 + Retry-After	Modelli e MCP tool

Token e request rate limit sullo stesso asset: la richiesta deve rispettarli entrambi.



GOVERNANCE · RATE LIMIT

Policy: token e request rate limit

Token rate limit

Modelli · 429 con Retry-After

Finestra: per minuto, ora o giorno

Conteggio: per identità del chiamante o per IP

Header di risposta: remaining-tokens e consumed-tokens; remaining-quota-tokens per finestre da un'ora in su

I client possono autoregolarsi

Request rate limit

Modelli e MCP tool · 429 con Retry-After

Finestre: per esempio 30 s, 1 min, 2 min, 5 min

Conteggio: per identità del chiamante o per IP

Utile per tool che chiamano sistemi SaaS o interni con quote rigide

CONFIGURAZIONE NEL PORTALE

Policies > Add policy → **Type** → **Assets** → **Configure** → **Create**



GOVERNANCE · BEST PRACTICE

Best practice di governance: baseline + override

OVERRIDE MIRATI

Modelli costosi

Token rate limit su modelli ad alto costo o con capacità limitata

Tool con quote

Request limit più stretto sul tool che chiama un'API downstream rate-limited

Controlli a strati

Token + request limit sullo stesso modello

Scope per identità

Una chiave runtime per app, limiti per identità: budget e attribuzione per app

BASELINE DEL GATEWAY · Content safety + IP filter su tutti gli asset

CONTENT SAFETY: ROLLOUT

Log-only → **Tuning su traffico reale** → **Block**

Categorie hate, sexual, violence, self-harm · 4 o 8 livelli di severità · Prompt Shields · blocklist

NOTA SUI COSTI

Le policy di governance sono controlli operativi. Per il reporting finanziario usa il billing del provider o Azure Cost Management.



NOVITÀ AGOSTO 2026 · COST LIMIT

Budget LLM per ogni modello

ESEMPIO DALLA DOCUMENTAZIONE

$100

al giorno, per API key

Spesa stimata massima su un dato modello.

Possibile un lieve sforamento temporaneo.

Budget in USD
Per ciascun modello selezionato

Rinnovo
Orario, giornaliero, settimanale, mensile o annuale, su finestre di calendario fisse

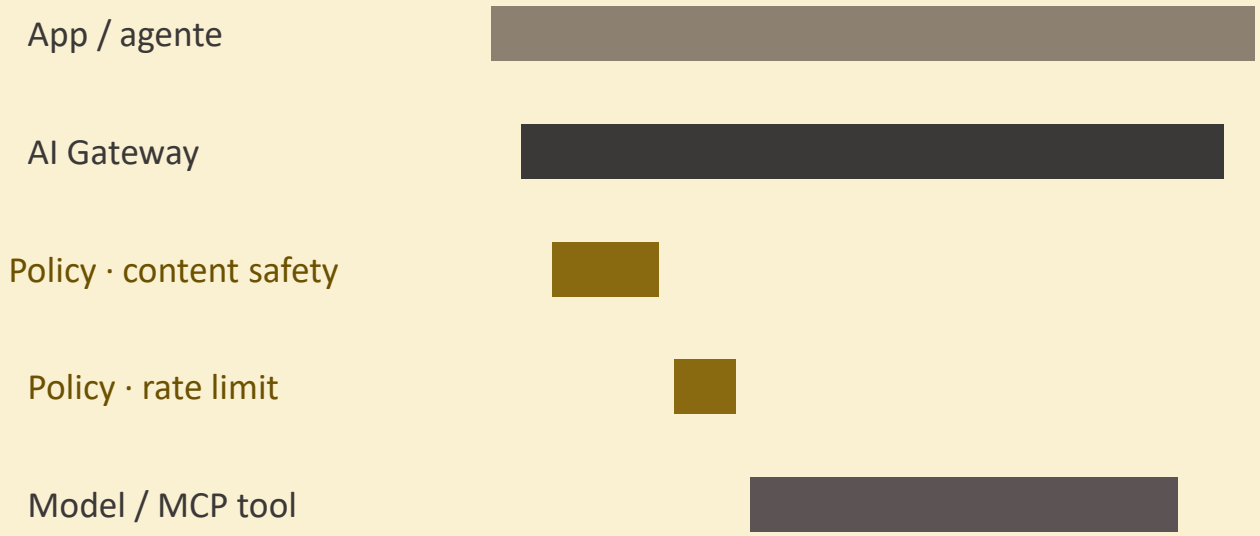
Per chiamante
Oggi per API key; il budget residuo arriva in un header di risposta

Oltre il limite
Richieste bloccate con risposta LlmCostQuotaExceeded

IN ARRIVO
Enforcement per principal Entra, budget di gateway, override per chiavi, utenti o gruppi

Ogni richiesta, tracciata end-to-end

TRACE WATERFALL · RAPPRESENTAZIONE SCHEMATICA



Le policy emettono child span: tipo, esito, latenza.

Logs, traces e metriche
Via OTLP: token, costo stimato, log e distributed traces

Destinazione a tua scelta
Application Insights o qualsiasi backend OpenTelemetry

Semantic conventions
GenAI e MCP (gen_ai.*), più attribuzione per API key

Monitoring integrato
Salute, attività, esiti, policy, token e costo stimato



Monitoraggio – nel dettaglio

ATTRIBUTI DELLA METRICA TOKEN

Attributo	Esempi / significato
`gen_ai.request.model`	Modello richiesto
`gen_ai.response.model`	Modello che ha risposto
`gen_ai.operation.name`	chat, responses
`gen_ai.token.type`	prompt_tokens, completion_tokens_details.reasoning_tokens

```
# PromQL – consumo di token per modello
sum by (gen_ai_request_model) (gen_ai_client_token_usage)
```

Destinazioni

Application Insights: dashboard integrata nel portale

OTLP: Datadog, Splunk, Grafana Cloud o collector generico; URL e token/header del collector da proteggere come segreti

ATTENZIONE · DATI MANCANTI

Alcuni provider omettono i token in streaming o passthrough: dato non disponibile, non zero.



Quale scegliere?

OPZIONE A · SCEGLILO QUANDO…

AI Gateway tier

- Vuoi un endpoint governato per molti modelli e tool MCP, con setup rapido
- Policy senza XML e chiavi centralizzate
- Telemetria OpenTelemetry pronta
- Connettori SaaS esposti come tool
- Accetti le condizioni di preview: pilot, carichi non critici, East US 2 / Sweden Central

OPZIONE B · CAPACITÀ AI GATEWAY DI APIM

APIM, tier esistenti

- Serve anche API management general-purpose
- Servono SLA di produzione
- Policy XML avanzate o personalizzate, semantic caching
- Load balancing e circuit breaker tra backend (es. PTU)
- API A2A, multi-regione o VNet injection
- Hai già un'istanza APIM in produzione

INSIEME

Approcci complementari. Non esiste un percorso di migrazione documentato tra i tier esistenti e AI Gateway tier.



QUANDO USARLO

Quando scegliere AI Gateway tier

SE IL TUO SCENARIO È…	…LA SCELTA È
Molti modelli e tool MCP dietro un endpoint governato, con setup rapido, policy senza XML e telemetria pronta; preview accettabile.	**AI Gateway tier** Un punto unico di controllo
Un solo modello, da una sola app, senza esigenze di governance.	**Chiamata diretta** Al provider: può essere più semplice
Servono anche API management general-purpose, SLA di produzione, policy XML avanzate, semantic caching o load balancing tra backend.	**APIM, tier esistenti** Capacità AI gateway · complementari



STATO PREVIEW

Public preview: cosa sapere

REGIONI DISPONIBILI

East US 2

Stati Uniti

Sweden Central

Europa · opzione UE

Nessuna SLA

Disponibilità best effort. API, portale, telemetria, limiti, regioni e pricing possono cambiare.

Quote di preview

Possono limitare modelli, tool, chiavi e throughput; limiti pubblicati prima della GA.

Pricing

Annunciato più avanti nella preview. Provider, Application Insights e rete hanno costi propri.

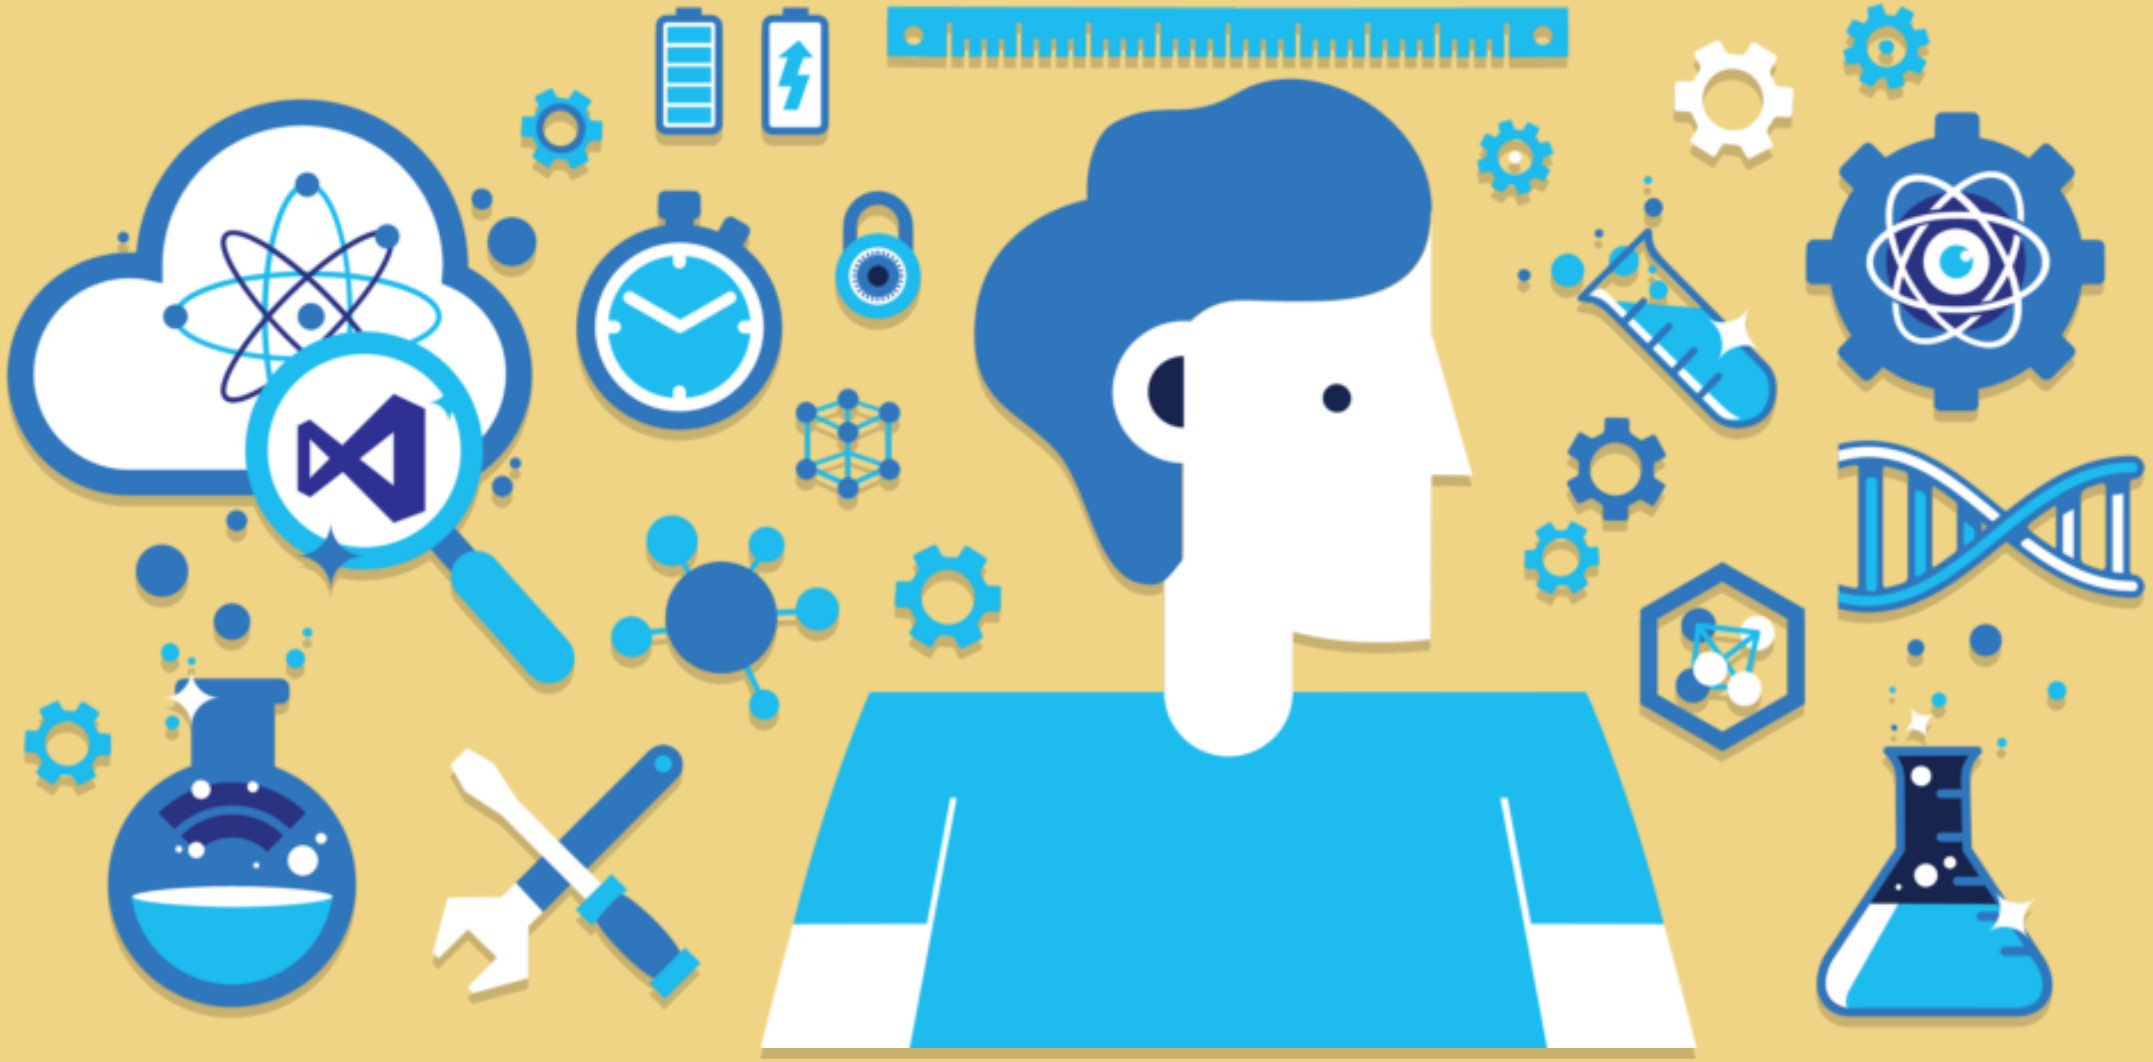
Data residency

Dipende dall'intero percorso: gateway, backend, tool, logging, identità e client.

Raccomandazione: workload non critici, pilot controllati, piano di rollback chiaro.

AZURE DAY

Demo



AZURE DAY TORINO 2026

Grazie a tutti!



Microsoft msc TECHNOLOGY TORINO.NET NET CODE

AZURE DAY

Platinum Sponsor

Microsoft

msc TECHNOLOGY

Technical Sponsor

TORINO NET

NET CODE

JET BRAINS

Staff



Giulio Sciarappa

Staff



Giulio Sciarappa



Luca Congiu

Staff



Giulio Sciarappa



Luca Congiu



Davide Bellone

Staff



Giulio Sciarappa



Luca Congiu



Davide Bellone



Savino Carlone

Partner Communities

2026 WPC

{codemotion} | AI & TECH CONFERENCE

Grusp

Powered by OVERNET.

WPC 2026

Supported by Microsoft

24, 25, 26 NOVEMBRE - NH MILANO CONGRESS CENTRE

25% OFF

Partecipando all'evento, hai diritto a uno sconto sui ticket WPC!

SOLO FINO al 17/10

Partner Communities



20%

PARTNER-DISC-20-TONET

Partner Communities



10%

community_torinodotnet

devsecopsday.it containerday.it

DevOps e container

devsecopsday **mercoledì 14 ottobre**
Software sicuro, automatizzato e resiliente

containerday **giovedì 15 ottobre**
Infrastrutture IT moderne, resilienti e scalabili

Bologna, Hotel Savoia Regency

Codice sconto -30%

AIAZURE26

Valido fino al 12 ottobre

mlopsday.it

L'AI su infrastrutture private e controllate

mlopsday

Bologna
Hotel Savoia Regency

Conferenza: **giovedì 29 ottobre**
LLM e RAG in produzione, fine-tuning, security e compliance, controllo dei costi

Workshop: **venerdì 30 ottobre**
Agent Core & Harness · Da Zero a Spec-Driven

Codice sconto -20%

AIAZURE26

Valido fino al 27 ottobe

dxday.it

Come l'AI sta riscrivendo la developer experience

dxday

Lunedì 12 aprile 2027
Bologna, Hotel Savoia Regency
Conferenza internazionale:
tutti i talk sono in inglese

Coding agent in produzione, metriche di produttività, piattaforme per workflow AI, cognitive load e code review, costi dei modelli

Call for papers
aperta fino al 30
novembre 2026

Prossimi eventi:

-22 Ottobre -> Meetup

-8 Gennaio -> Bonanni a Tutti!

Bonanni A Tutti!



AI & AZURE DAY TORINO 2026

Ti è piaciuto AI & Azure Day?

Facci sapere cosa ti è piaciuto o aiutaci a migliorare rispondendo al sondaggio.



Microsoft

msc TECHNOLOGY

TORINO.NET

NET CODE

AI & AZURE DAY TORINO 2026

Per Avere l'attestato di partecipazione basterà registrarsi al link che trovi nel QR code.

Riceverai l'attestato nella tua posta e potrai aggiungerlo al tuo profilo linkedin



Microsoft

msc TECHNOLOGY

TORINO.NET

NET CODE

AI & AZURE DAY TORINO 2026

SELFIE LOTTERY

Partecipa con semplice selfie alla lotteria finale per vincere uno dei fantastici premi messi in palio dai nostri sponsor!



Microsoft

msc TECHNOLOGY

TORINO NET

NET CODE

AZURE DAY TORINO 2026

Grazie a tutti!



Microsoft msc TECHNOLOGY TORINO.NET NET CODE



DEMO · 5 MINUTI

Demo – [da definire]

Flusso proposto, end-to-end sul nuovo tier AI Gateway

01 Creare il gateway nel portale

02 Importare un modello da Foundry

03 Token rate limit e budget

04 Chiamata con api-key

05 Trace in Application Insights



IN SINTESI

Cinque cose da ricordare

1. Un AI Gateway centralizza chiavi, quote, sicurezza e osservabilità per modelli e tool MCP.
2. APIM classic e v2: capacità AI gateway su tutti i tier, GA con SLA, policy XML con espressioni.
3. Nuovo tier AI Gateway: esperienza dedicata, provisioning in circa un minuto, policy a card, MCP federato.
4. Il nuovo tier è in public preview: nessuno SLA, due regioni, pricing da annunciare.
5. Scegliere in base a SLA, regioni, policy e rete: i due approcci possono coesistere.



RISORSE

Per approfondire (1/2)

AI gateway in Azure API Management – panoramica

https://learn.microsoft.com/en-us/azure/api-management/ai-gateway-overview

Capacità GenAI gateway in API Management

https://learn.microsoft.com/en-us/azure/api-management/genai-gateway-capabilities

Panoramica dei tier v2 di API Management

https://learn.microsoft.com/en-us/azure/api-management/v2-service-tiers-overview

Documentazione del portale AI Gateway

https://ai.gateway.azure.com/docs

Release notes AI Gateway – 28 agosto 2026

https://ai.gateway.azure.com/docs/releases/2026-08-28

Release notes AI Gateway – 10 settembre 2026

https://ai.gateway.azure.com/docs/releases/2026-09-10

Tech Community – annuncio della public preview del tier AI Gateway

https://techcommunity.microsoft.com/blog/integrationsonazureblog/ai-gateway-tier-of-api-management-now-in-public-preview/4540170



RISORSE

Per approfondire (2/2): i dettagli

Unified model API in API Management

https://learn.microsoft.com/en-us/azure/api-management/unified-model-api

Policy llm-content-safety

https://learn.microsoft.com/en-us/azure/api-management/llm-content-safety-policy

Rete privata per il tier AI Gateway

https://learn.microsoft.com/en-us/azure/api-management/ai-gateway-configure-private-networking

Setup wizard del tier AI Gateway

https://learn.microsoft.com/en-us/azure/api-management/ai-gateway-setup

Policy del nuovo tier – portale AI Gateway

https://ai.gateway.azure.com/docs/policies

Networking del nuovo tier – portale AI Gateway

https://ai.gateway.azure.com/docs/networking



Questions & Discussion



AZURE DAY



Vote for this session!!

https://vote.dotnetdev.it/vote/l44tzzta/1326620